

Pipeline de Données pour l'Analyse Comparative des Produits Parapharmaceutiques

Aymane Naaimi

Agenda

- 1 Introduction
- 2 Structure du projet
- 3 Collecte des données (Scraping)
- 4 Nettoyage & Transformation
- 5 Appariement des produits
- 6 Orchestration du pipeline
- 7 Tableau de bord & Analyses
- 8 Conclusion & Perspectives

- Objectif : créer un **dataset exhaustif** de produits parapharmaceutiques.
- Sources : `parapharma.ma` et `universparadiscount.ma`.
- Chaîne de valeur : **scraping** → **nettoyage** → **appariement** → **tableau de bord**.
- Code organisé dans le dépôt `paraMed_pipeline`.

Structure du projet

- `config.py` : paramètres globaux (modèle d'embeddings, seuils, catégories, marques).
- `scrapers/` : récupération des produits (pagination, prix, disponibilité).
- `utils/` : nettoyage (normalisation, extraction marque & taille, mapping catégories), I/O MongoDB.
- `transform.py` : fusion, déduplication, normalisations.
- `matcher.py` : appariement par *embeddings* sémantiques.
- `main.py` : orchestration & point d'entrée (`run_pipeline`).

Catégories configurées

- Listes par site (ex. Visage, Corps, Maquillage, Cheveux, Solaire...).
- Extensibles sans modifier la logique.

Scraper Parapharma

- Parsing des pages catégories (pagination) avec BeautifulSoup.
- Extraction : nom, URL, image, prix/remise, disponibilité.
- Calcul du prix initial & indicateur de promotion.

Scraper Univers ParaDiscount

- Logique analogue, adaptée à la structure des pages Univers.
- Gestion des prix normal/remisé & disponibilité.

Normalisation des noms

- Minuscules, suppression des accents, espaces normalisés.
- Récupération depuis l'URL d'image si nom tronqué (...).

Extraction des attributs

- *Marque* (liste de marques connues + heuristiques).
- *Taille* (ex. 30ml, 200g).

Nettoyage prix, disponibilité, catégories

- Parsing des prix (float), normalisation disponible/indisponible.
- Mapping des catégories → catégories canoniques.

Fusion & déduplication

- Schéma unifié, dédoublonnage par (site, clean_name).

- Regroupement des candidats par **(marque, taille)**.
- Construction des chaînes d'appariement : `marque + clean_name + taille`.
- Embeddings (par défaut : `paraphrase-multilingual-MiniLM-L12-v2`).
- Similarité cosinus, seuil **0.90** ; on conserve le *meilleur match* si plusieurs.

Orchestration du pipeline

- `run_pipeline()` : scraping → transformation → stockage → appariement.
- Paramètres : `max_pages` par site, variables d'environnement MongoDB.
- Collections : `para_univer_merged` (nettoyés), `matches` (appariés).

Tableau de bord & Analyses (1/2)

- **# Produits** : $\sim 22,7k$ références uniques.
- **Marques/Catégories** : $\sim 1,374$ marques, ~ 203 catégories.
- **Disponibilité** : $\sim 87\%$ disponible, $\sim 13\%$ rupture.
- **Promotions** : $\sim 24,7\%$ des produits remisés.

- **Distribution des prix** : majorité $< 0,4k$ MAD, longue traîne.
- **Analyse par catégorie** : prix moyens plus élevés en Para-médical & Compléments/Santé.
- **Produits phares** : comparaison inter-sites, filtres par site/marque/catégorie.

Conclusion

- Pipeline modulaire, reproductible, extensible (code + dashboard).
- Normalisations cohérentes → appariement précis et analyses fiables.

Pistes d'amélioration

- Matching enrichi
- Nouvelles sources e-commerce.
- Analyses avancées (anomalies de prix, prévisions, recommandations).